Creado por:

Isabel Maniega

GraphFrames

Realizaremos la instalación de la librería de Graphframes:

```
In [1]: # pip install graphframes
In [3]: import pyspark
import os

In [4]: os.environ["PYSPARK_SUBMIT_ARGS"] = "--packages graphframes:graphframes:0
In [5]: conf = pyspark.SparkConf()
In [6]: sc = pyspark.SparkContext(conf=conf)
print(sc._conf.getAll())
```

[('spark.driver.extraJavaOptions', '-XX:+IgnoreUnrecognizedVMOptions --a dd-opens=java.base/java.lang=ALL-UNNAMED --add-opens=java.base/java.lan g.invoke=ALL-UNNAMED --add-opens=java.base/java.lang.reflect=ALL-UNNAMED --add-opens=java.base/java.io=ALL-UNNAMED --add-opens=java.base/java.net =ALL-UNNAMED --add-opens=java.base/java.nio=ALL-UNNAMED --add-opens=jav a.base/java.util=ALL-UNNAMED --add-opens=java.base/java.util.concurrent= ALL-UNNAMED --add-opens=java.base/java.util.concurrent.atomic=ALL-UNNAME D --add-opens=java.base/sun.nio.ch=ALL-UNNAMED --add-opens=java.base/su n.nio.cs=ALL-UNNAMED --add-opens=java.base/sun.security.action=ALL-UNNAM ED --add-opens=java.base/sun.util.calendar=ALL-UNNAMED --add-opens=java. security.jgss/sun.security.krb5=ALL-UNNAMED'), ('spark.app.initial.jar.u rls', 'spark://dc42b531111e:39853/jars/org.slf4j slf4j-api-1.7.16.jar,sp ark://dc42b531111e:39853/jars/graphframes graphframes-0.8.1-spark3.0-s 2.12.jar'), ('spark.app.submitTime', '1669719894100'), ('spark.executor. id', 'driver'), ('spark.submit.pyFiles', '/home/jovyan/.ivy2/jars/graphf rames_graphframes-0.8.1-spark3.0-s_2.12.jar,/home/jovyan/.ivy2/jars/org. slf4j slf4j-api-1.7.16.jar'), ('spark.app.name', 'pyspark-shell'), ('spa rk.jars', 'file:///home/jovyan/.ivy2/jars/graphframes graphframes-0.8.1spark3.0-s 2.12.jar,file:///home/jovyan/.ivy2/jars/org.slf4j slf4j-api-1.7.16.jar'), ('spark.app.id', 'local-1669719894732'), ('spark.app.start Time', '1669719894214'), ('spark.rdd.compress', 'True'), ('spark.executo r.extraJavaOptions', '-XX:+IgnoreUnrecognizedVMOptions --add-opens=java. base/java.lang=ALL-UNNAMED --add-opens=java.base/java.lang.invoke=ALL-UN NAMED --add-opens=java.base/java.lang.reflect=ALL-UNNAMED --add-opens=ja va.base/java.io=ALL-UNNAMED --add-opens=java.base/java.net=ALL-UNNAMED --add-opens=java.base/java.nio=ALL-UNNAMED --add-opens=java.base/java.uti l=ALL-UNNAMED --add-opens=java.base/java.util.concurrent=ALL-UNNAMED --a dd-opens=java.base/java.util.concurrent.atomic=ALL-UNNAMED --add-opens=j ava.base/sun.nio.ch=ALL-UNNAMED --add-opens=java.base/sun.nio.cs=ALL-UNN AMED --add-opens=java.base/sun.security.action=ALL-UNNAMED --add-opens=j ava.base/sun.util.calendar=ALL-UNNAMED --add-opens=java.security.jgss/su n.security.krb5=ALL-UNNAMED'), ('spark.app.initial.file.urls', 'file:/// home/jovyan/.ivy2/jars/graphframes_graphframes-0.8.1-spark3.0-s_2.12.ja r,file:///home/jovyan/.ivy2/jars/org.slf4j_slf4j-api-1.7.16.jar'), ('spa rk.serializer.objectStreamReset', '100'), ('spark.master', 'local[*]'), ('spark.submit.deployMode', 'client'), ('spark.driver.port', '39853'), ('spark.driver.host', 'dc42b531111e'), ('spark.files', 'file:///home/jov yan/.ivy2/jars/graphframes_graphframes-0.8.1-spark3.0-s_2.12.jar,fil e:///home/jovyan/.ivy2/jars/org.slf4j_slf4j-api-1.7.16.jar'), ('spark.re pl.local.jars', 'file:///home/jovyan/.ivy2/jars/graphframes_graphframes-0.8.1-spark3.0-s 2.12.jar,file:///home/jovyan/.ivy2/jars/org.slf4j slf4j -api-1.7.16.jar'), ('spark.ui.showConsoleProgress', 'true')]

Creamos el Grafo

("G", "GERARDO", 30),

```
("H", "HERNANDO", 25),
         ("I", "INMA", 25 ),
("J", "JUAN" , 20 )
], ["id", "name", "total_points"])
         v.show()
         +---+
         | id| name|total_points|
         +---+
           A| ANA| 350|
                BERT0|
           B|
                                360|
                 CLARA|
                               195|
           Cl
         | D|
                                90|
               DANIEL
           E| ERICA|
                                901
           F|FRANCISCO|
                               215
                               30|
           G| GERARDO|
         | H| HERNANDO|
                                25|
         | I|
                                25|
                   INMA
                                201
            JΙ
                   JUAN|
In [14]: e = spark.createDataFrame([
             ("A", "B", 60),
("B", "A", 60),
             ("A", "C", 50),
             ("D", "A", 100),
("A", "D", 80),
("C", "I", 25),
             ("C", "J", 20),
             ("B", "F", 50),
("F", "B", 60),
             ("F", "G", 110),
             ("F", "H", 25),
             ("B", "E", 90),
         ], ["src", "dst", "relationship"])
         e.show()
         +---+
         |src|dst|relationship|
         +---+---+
            A| B|
                           60 l
            B| A|
                          60|
                           50|
            A| C|
           D| A|
                          100|
            A| D|
                          80|
            C| I|
                           25|
            C \mid
                          20|
               J
                          50|
           B| F|
            F| B|
                          60|
            F| G|
                          110|
            FΙ
               H
                           25|
            B| E|
                           90|
In [15]: g = GraphFrame(v,e)
```

/usr/local/spark/python/pyspark/sql/dataframe.py:148: UserWarning: DataFrame.sql_ctx is an internal property, and will be removed in future rele ases. Use DataFrame.sparkSession instead.

warnings.warn(

Atributos básicos Graph:

• Definimos cual corresponde al vértice y cual a la arista:

```
In [16]: verticesDF = g.vertices
       edgesDF = g.edges
In [17]: verticesDF.show()
        | id| name|total_points|
        +---+-----+
         A| ANA| 350|
          B|
              BERT0|
                           360
             CLARA|
                          195|
         C |
         D |
              DANIEL|
                           90|
                           90|
         Εl
              ERICA|
          F|FRANCISCO|
                           215
          G| GERARDO|
                             30|
          H| HERNANDO|
                            25|
          Ι|
                INMA|
                            25|
          J
                JUAN|
                            20|
```

In [18]: edgesDF.show()

```
+---+
|src|dst|relationship|
+---+---+
  B| A|
             60|
             50|
  A| C|
            100|
  D| A|
 A| D|
             80|
  C| I|
              25|
 C| J|
              20|
  B| F|
             50|
  FI BI
              60|
  FΙ
    G|
              110|
  F|
    H
             25|
  B| E|
              90|
```

- inDegrees, outDegrees y degrees:
 - inDegrees: son las entradas del nodo
 - outDegrees: son las salidas del nodo
 - degrees: son todas las conexiones por nodo

```
In [21]: inDegreesDF = g.inDegrees
         outDegreesDF = g.outDegrees
         degreesDF = g.degrees
In [23]: inDegreesDF.sort(['inDegree'],ascending=[0]).show() # Sort and show
         +---+
         | id|inDegree|
           --+----+
           B|
                    2|
           Α|
                    2|
           C \mid
           DΙ
                   1|
                   1|
           JΙ
           G|
                   1|
           Ιl
                   1|
           FΙ
                    1|
           Εl
                    1|
           ΗI
                    1|
In [24]: outDegreesDF.sort(['outDegree'],ascending=[0]).show() # Sort and show
         +---+
         | id|outDegree|
         +---+
           FΙ
                     3|
                  3|
           B
           Α|
                    3|
           C |
                    2|
           D |
                    1|
In [26]: degreesDF.show() # Sort and show
         +---+
         | id|degree|
           Βl
           Αl
                  5|
           CI
                  31
           D
                  2|
           Ιl
                  1|
           J
                  1|
           F
                  4|
           G|
                  1|
           ΕI
                  1|
           ΗI
                  1|
```

Estructura Graph

 PageRank: Permite calcular los pesos para cada nodo o lo que es lo mismo asignar de forma numérica la relevancia de los nodos.

```
In [27]: PageRankResult = g.pageRank(resetProbability=0.15, tol=0.01)
PageRankResult.vertices.sort(["pageRank"],ascending=[0]).show()
```

```
In [29]: PageRankResult.edges.show()
```

```
+---+---+
|src|dst|relationship| weight|
+---+---+
     F| G|
  Η|
 F|
 B| F|
 BI EI
 B| A|
       100|
 D| A|
                  1.0
        20|
25|
 C[J]
                  0.5|
 C| I|
        Al Bl
 Al DI
 A| C|
```

 Label Propagation Algorithm (LPA): Poder obtener la relación entre nodos obteniendo los grupos que lo forman, asignando una etiqueta a cada grupo.

```
In [30]: result = g.labelPropagation(maxIter=5)
    result.sort(["label"],ascending=[0]).show()
```

```
+---+-----+
| id| name|total_points|
+---+-----+
       CLARA| 195|1391569403904|
 Ιl
                     25| 764504178688|
20| 764504178688|
        INMA|
         JUAN|
  JI
                  20| 764504178688|

215| 420906795008|

350| 420906795008|

90| 420906795008|

360| 171798691840|
  F|FRANCISCO|
  A | ANA |
  Εl
        ERICA|
       BERT0|
  Βl
                     90| 171798691840|
  D |
     DANIEL|
  G| GERARDO|
                      30 | 171798691840 |
                      25 | 171798691840 |
  H| HERNANDO|
```

 Connected Components: Observar cuales la conexión entre los nodos, si hay nodos aislados o no.

```
sc.setCheckpointDir("graphframes cps")
In [32]:
          result = g.connectedComponents()
          result.show()
          +---+-----+
                   name|total points| component|
          +---+-----+
                    ANA | 350 | 171798691840 |
BERTO | 360 | 171798691840 |
CLARA | 195 | 171798691840 |
             B|
             Cl
                   CLARA|
                                    90|171798691840|
90|171798691840|
             DΙ
                 DANIEL|
                   ERICA|
                                 215 | 171798691840 |

215 | 171798691840 |

30 | 171798691840 |

25 | 171798691840 |
             F|FRANCISCO|
             G| GERARDO|
             H| HERNANDO|
                                     25 | 171798691840 |
             Ιl
                     INMA
             J|
                     JUAN|
                                     20|171798691840|
```

• Strongly Connected Components: Ver que nodos están fuertemente conectados.

```
In [33]: result = g.stronglyConnectedComponents(maxIter=10)
        result.show()
        +---+-----+
               name|total_points| component|
        +---+-----+
          F|FRANCISCO| 215| 171798691840|
                          90| 369367187456|
360| 171798691840|
90| 171798691840|
195| 764504178688|
          Εl
               ERICA|
          Βl
                BERT0|
               DANIEL|
          DΙ
          C |
             CLARA|
          JΙ
                            20 | 807453851648 |
               JUAN|
                           350| 171798691840|
                ANA|
          Α|
                           30|1168231104512|
25|1391569403904|
          G١
             GERARD0|
          Ιl
              INMA|
          H| HERNANDO| 25|1683627180032|
          --+----+
```

Triangle count: Cuenta el número de triángulos para cada nodo en el gráfico y
calcula el coeficiente de agrupamiento promedio para la red de nodos resultante.
 Un triángulo se define como tres nodos que están conectados por tres bordes (a-b,
b-c, c-a).

```
In [34]: result = g.triangleCount()
    result.show()
```

30/11/22, 9:22 Tema 106 Grafos

++	+	+	+
count	id	name	total_points
++	+	+	+
0	Α	ANA	350
0	B	BERT0	360
0	C	CLARA	195
0	D	DANIEL	90
0	Εİ	ERICA	90
0	FİI	FRANCISCO	215
0	G	GERARDO	30
0	ΗĮ	HERNANDO	25
0	Ιļ	INMA	25
0	J	JUAN	20
++	+	+	+

No existe agrupamiento para ese ejemplo

• Shortest paths: Calcula la ruta más corta (ponderada) entre un par de nodos.

```
In [35]: result = g.shortestPaths(landmarks=["B"])
       result.show()
       +---+-----+
       | id| name|total_points|distances|
       +---+------+
         F|FRANCISCO| 215| {B -> 1}|
                        90| {}|
        E| ERICA|
                       360| {B -> 0}|
         ВΙ
            BERT0|
           DANIEL|
                        90| {B -> 2}|
         DΙ
                       195 | {} |
20 | {} |
         C| CLARA|
        J|
             JUAN|
        Α|
                       350| {B -> 1}|
             ANA|
           GERARD0 |
                       30|
        G١
                                {}|
                        25|
         I| INMA|
                                {}|
        H| HERNANDO|
                        25|
                                {}|
       +---+-----+
```

 Breadth-first search (BFS): Recorrer el gráfico desde el nodo raíz y explora todos los nodos vecinos. Luego, selecciona el nodo más cercano y explora todos los nodos inexplorados. El algoritmo sigue el mismo proceso para cada uno de los nodos más cercanos hasta que encuentra el objetivo.

• Subgraphs: Selecciona los nodos que cumplen una serie de normas.

```
In [38]: g2 = g.filterEdges("relationship = 50").filterVertices("total points > 30")
       q2.vertices.show()
       +---+----+
             name|total points|
       +---+----+
              ANA|
         Αl
                          350|
        Bl
             BERT0|
                          360|
              CLARA|
       | C|
                          195|
       | F|FRANCISCO|
                         215|
       +---+-----+
```

+---+

 Motif finding: Se conoce como coincidencia de patrones de gráficos. La coincidencia de patrones encuentra algún patrón dentro del gráfico. El patrón es una expresión que se usa para definir algunos vértices conectados.

Creado por:

Isabel Maniega