

Creado por:

Isabel Maniega

# VAEX y DASK

Objetivos:

- Aprender más sobre VAEX y DASK
- Fomentar la proactividad del alumno

## Tabla de contenidos:

- Profundizando en DASK
  - Lectura de datos películas
  - Lectura de datos valoraciones
  - Lectura de datos etiquetas
  - Combinación de datos
  - Valoraciones por año
  - Etiquetas más valoradas
  - Top usuarios con más valoraciones por tags

## Profundizando en DASK

Para este apartado trabajaré con el dataset de Movielens, que contiene información sobre películas y valoraciones de usuarios.

```
In [1]: import dask.dataframe as dd
import pandas as pd
import matplotlib.pyplot as plt
```

### Lectura de datos películas

```
In [2]: df_movies: dd.DataFrame = dd.read_csv('movies_data/movies.csv')
df_movies.head()
```

	movieId	title	genres
0	1	Toy Story (1995)	Adventure Animation Children Comedy Fantasy
1	2	Jumanji (1995)	Adventure Children Fantasy
2	3	Grumpier Old Men (1995)	Comedy Romance
3	4	Waiting to Exhale (1995)	Comedy Drama Romance
4	5	Father of the Bride Part II (1995)	Comedy

### Lectura de datos valoraciones

```
In [3]: df_ratings: dd.DataFrame = dd.read_csv('movies_data/ratings.csv')
df_ratings.head()
```

	userId	movieId	rating	timestamp
0	1	2	3.5	1112486027
1	1	29	3.5	1112484676
2	1	32	3.5	1112484819
3	1	47	3.5	1112484727
4	1	50	3.5	1112484580

### Lectura de datos etiquetas

```
In [4]: df_tags: dd.DataFrame = dd.read_csv('movies_data/tags.csv')
df_tags.head()
```

	userId	movieId	tag	timestamp
0	18	4141	Mark Waters	1240597180
1	65	208	dark hero	1368150078
2	65	353	dark hero	1368150079
3	65	521	noir thriller	1368149983
4	65	592	dark hero	1368150078


## Combinación de datos

```
In [5]: # Merge the three dataframes
df_mov_rat: dd.DataFrame = df_ratings.merge(df_movies, on='movieId', how='left')
df_movieltags: dd.DataFrame = df_mov_rat.merge(df_tags, on=['userId', 'movieId'], how='left')
# rename timestamp_x to rating_timestamp and timestamp_y to tag_timestamp
df_movieltags: dd.DataFrame = df_movieltags.rename(columns={'timestamp_x': 'rating_timestamp', 'timestamp_y': 'tag_timestamp'})
df_movieltags["rating_timestamp"] = dd.to_datetime(df_movieltags["rating_timestamp"], unit='s', origin='unix')
df_movieltags["tag_timestamp"] = dd.to_datetime(df_movieltags["tag_timestamp"], unit='s', origin='unix')
df_movieltags.head()
```

	userId	movieId	rating	rating_timestamp	title	genres	tag	tag_timestamp
0	1	2	3.5	2005-04-02 23:53:47	Jumanji (1995)	Adventure Children Fantasy	NaN	NaT
1	1	29	3.5	2005-04-02 23:31:16	City of Lost Children, The (Cité des enfants p...	Adventure Drama Fantasy Mystery Sci-Fi	NaN	NaT
2	1	32	3.5	2005-04-02 23:33:39	Twelve Monkeys (a.k.a. 12 Monkeys) (1995)	Mystery Sci-Fi Thriller	NaN	NaT
3	1	47	3.5	2005-04-02 23:32:07	Seven (a.k.a. Se7en) (1995)	Mystery Thriller	NaN	NaT
4	1	50	3.5	2005-04-02 23:29:40	Usual Suspects, The (1995)	Crime Mystery Thriller	NaN	NaT

## Valoraciones por año

```
In [6]: # plot the number of ratings per year
df_movieltags.groupby(df_movieltags.rating_timestamp.dt.year)\
    .rating\
    .count()\
    .compute()\
    .plot(kind='bar')
plt.show()
```



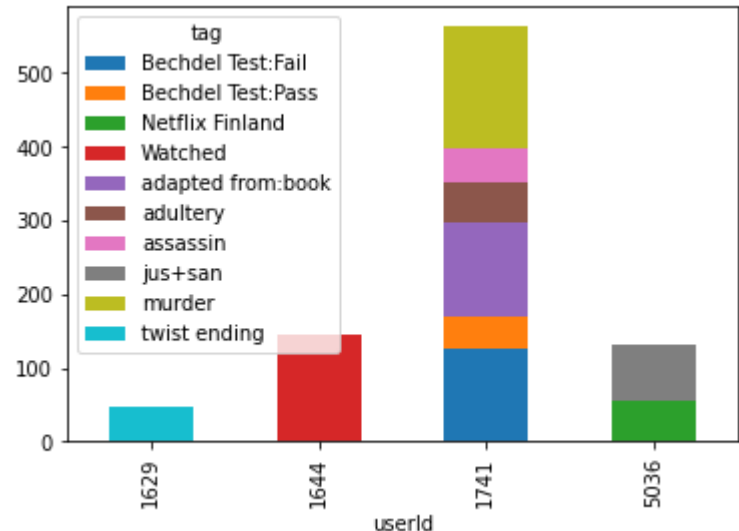
## Etiquetas más valoradas

```
In [7]: # plot the top tags rated by users as pie
df_movieltags.groupby('tag')\
    .rating\
    .count()\
    .nlargest(10)\
    .compute()\
    .plot(kind='pie')
plt.show()
```



## Top usuarios con más valoraciones por tags

```
In [8]: # plot the top 10 users who rated the most movies with the legend as the tag
df_movieltags[['userId', 'tag', 'rating']]\
    .groupby(['userId', 'tag'])\
    .rating\
    .count()\
    .nlargest(10)\
    .compute()\
    .unstack()\
    .plot(kind='bar', stacked=True)
plt.show()
```



Creado por:

Isabel Maniega