Creado por:

Isabel Maniega

Las reglas de asociación normalmente se escriben así: {Pañales} -> {Cerveza}, lo que significa que existe una fuerte relación entre los clientes que compraron pañales y también compraron cerveza en la misma transacción.

El soporte (support) es la frecuencia relativa con la que aparecen las reglas. En muchos casos, es posible que desee buscar un alto apoyo para asegurarse de que sea una relación útil. Sin embargo, puede haber casos en los que un soporte bajo sea útil si está

tratando de encontrar relaciones "ocultas". La confianza (confidence) es una medida de la fiabilidad de la regla. Una confianza de .5 en el ejemplo anterior significaría que en el 50

% de los casos en los que se compraron pañales y chicles, la compra también incluyó cerveza y papas fritas. Para la recomendación de productos, una confianza del 50 % puede ser perfectamente aceptable, pero en una situación médica, este nivel puede no ser lo suficientemente alto.

Elevación (Lift) es la relación entre el soporte observado y el esperado si las dos reglas fueran independientes (ver wikipedia). La regla general básica es que un valor de elevación cercano a 1 significa que las reglas son completamente independientes. Los valores de

elevación > 1 son generalmente más "interesantes" y podrían ser indicativos de un patrón de regla útil.

Description Quantity

BOTTLE

12

MESSAGE

CARDS

WITH

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

12 PENCIL

WOODLAND

SMALL

TUBE

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

/home/isabelmaniega/FEI_projects/venv/lib/python3.8/site-packages/mlxtend/frequent_patterns/fpcommon.py:111: De

consequent

support

0.102041

0.096939

0.094388

0.096939

consequent

support

0.094388

0.096939

0.132653 0.102041

0.127551 0.122449

0.137755 0.122449

0.127551 0.099490

0.132653 0.099490

0.137755 0.099490

consequent

support

0.137856

support

0.070022

support confidence

0.067834

0.137856 0.061269

0.126915 0.059081

support confidence

support confidence

0.763158 7.478947

0.815789 8.642959

0.815789 8.642959

0.837838 8.642959

0.888889

0.800000 6.030769 0.085121

0.960000 6.968889 0.104878

0.975000 7.644000 0.086474

0.812500 6.125000 0.083247

0.975000 7.077778 0.085433

6.968889 0.104878

0.725000

0.837838

7.478947

8.642959

0.783784 7.681081 0.064348

0.073980

0.073980

0.079082

0.079082

0.079082

0.079082

0.102041 0.073980

12 PENCILS

TUBE RED

RETROSPOT

SMALL

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

CREAM CUPID HEARTS COAT HANGER

KNITTED UNION FLAG HOT WATER

6

6

8

6

6

InvoiceDate UnitPrice CustomerID

2.55

3.39

2.75

3.39

3.39

17850.0

17850.0

17850.0

17850.0

17850.0

2010-12-01

2010-12-01

2010-12-01

2010-12-01

2010-12-01

08:26:00

08:26:00

08:26:00

08:26:00

08:26:00

12

PENCILS

SMALL

TUBE

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

SKULL

12

TALL

TUBE

POSY

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

PENCILS

12 PENCILS

TALL TUBE

RETROSPOT

RED

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

leverage conviction

3.791383

3.283859

4.916181

5.568878

4.153061

4.916181

5.568878

4.336735

7.852041

21.556122

34.897959

4.625850

34.489796

lift leverage conviction

2.076984

2.011670

5.587746

0.584906 4.242887 0.051846

0.571429 4.145125 0.046488

 $0.843750 \quad 6.648168 \quad 0.050194$

0.064088

0.064088

0.069932

0.069932

lift leverage conviction

0.069932

0.069932

Country

United

United

United

United

United

Kingdom

Kingdom

Kingdom

Kingdom

Kingdom

12 PENCILS

TALL TUBE

WOODLAND

0.0 ..

0.0 ..

0.0 ..

0.0 ..

0.0 ..

0.0

0.0

0.0

0.0 ..

0.0 ..

En el ejemplo anterior, {Pañal} es el antecedente y {Cerveza} es el consecuente. Tanto los antecedentes como los consecuentes pueden tener varios elementos. En otras palabras, {pañal, chicle} -> {cerveza, papas fritas} es una regla válida.

Market Basket Analysis

Teoría

In [4]: import pandas as pd from mlxtend.frequent_patterns import apriori from mlxtend.frequent_patterns import association_rules

pip install xlrd

pip install openpyxl

pip install mlxtend

In [1]:

In [3]:

2

3

basket

InvoiceNo

536370

536852

536974

580986

581001

Out[11]:

In [12]:

In [13]:

Out[14]:

Out[15]:

1

df.head()

InvoiceNo StockCode

536365

536365

Out[4]: 0 536365 85123A WHITE HANGING HEART T-LIGHT HOLDER 1 536365 71053 WHITE METAL LANTERN

84406B

84029G

4 536365 84029E RED WOOLLY HOTTIE WHITE HEART. In [10]: df['Description'] = df['Description'].str.strip() df.dropna(axis=0, subset=['InvoiceNo'], inplace=True)

In [11]: basket = (df[df['Country'] == "France"]

.groupby(['InvoiceNo', 'Description'])['Quantity'] .sum().unstack().reset_index().fillna(0) .set index('InvoiceNo'))

12

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

12 EGG

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

0.0

frequent_itemsets = apriori(basket_sets, min_support=0.07, use_colnames=True)

rules = association_rules(frequent_itemsets, metric="lift", min_threshold=1)

consequents

(ALARM CLOCK

BAKELIKE PINK)

(ALARM CLOCK

(ALARM CLOCK

BAKELIKE RED)

(ALARM CLOCK

(ALARM CLOCK

BAKELIKE PINK)

consequents

(ALARM CLOCK

BAKELIKE RED)

(ALARM CLOCK

(SET/20 RED

NAPKINS)

BAKELIKE GREEN)

RETROSPOT PAPER

(SET/6 RED SPOTTY

(SET/6 RED SPOTTY

(SET/6 RED SPOTTY

RETROSPOT PAPER

(SET/6 RED SPOTTY

.groupby(['InvoiceNo', 'Description'])['Quantity']

WOODLAND ANIMALS)

(WOODLAND

CHARLOTTE BAG)

.sum().unstack().reset_index().fillna(0)

In [16]: # Número de datos que contiene la regla usada: "ALARM CLOCK BAKELIKE GREEN"

PAPER PLATES)

PAPER CUPS)

PAPER PLATES)

(SET/20 RED

PAPER CUPS)

NAPKINS)

BAKELIKE GREEN)

BAKELIKE GREEN)

antecedent

support

0.096939

0.102041

0.096939

0.094388

0.094388

antecedent

support

0.096939

0.094388

0.127551

0.137755

0.127551

0.102041

0.122449

0.102041

df['InvoiceNo'] = df['InvoiceNo'].astype('str') df = df[~df['InvoiceNo'].str.contains('C')]

Realizaremos un análisis para la compra en Francia

COLOUR HOUSE **COLOURED** Description **SPACEBOY PARTY PAINTED** PEN **BALLOONS** WOOD **ENVELOPES**

10

0.0

0.0

0.0

0.0

0.0

0.0

537065 0.0 537463 0.0

581171 0.0 581279 0.0 581587

392 rows × 1563 columns # convertir los menores de 0 en 0 y mayores de 1 en 1

def encode_units(x): **if** x <= 0:

return 0

Realizamos el modelo:

In [14]: # Realizarmos la regla de asociación:

(ALARM CLOCK

BAKELIKE PINK)

if x >= 1: return 1 basket sets = basket.applymap(encode units) basket_sets.drop('POSTAGE', inplace=True, axis=1)

precationWarning: DataFrames with non-bool types result in worse computationalperformance and their support mig ht be discontinued in the future. Please use a DataFrame with bool type warnings.warn(

rules.head()

antecedents (ALARM CLOCK 0 **BAKELIKE GREEN)**

(ALARM CLOCK 2 **BAKELIKE GREEN)** (ALARM CLOCK **BAKELIKE RED)** (ALARM CLOCK 4

BAKELIKE RED) In [15]: # Filtrar por los valores de lift (elevación) mayores o iguales a 6 y # de confianza (confidence) mayores o iguales a 0.8

rules[(rules['lift'] >= 6) & (rules['confidence'] >= 0.8)] antecedents (ALARM CLOCK BAKELIKE

GREEN)

CUPS)

PLATES)

RETRO...

basket["ALARM CLOCK BAKELIKE GREEN"].sum()

(SET/6 RED SPOTTY PAPER 16 PLATES) (SET/6 RED SPOTTY PAPER

(ALARM CLOCK BAKELIKE

(SET/6 RED SPOTTY PAPER

(SET/6 RED SPOTTY PAPER

CUPS, SET/20 RED

(SET/6 RED SPOTTY PAPER CUPS, SET/6 RED SPOTTY... (SET/6 RED SPOTTY PAPER PLATES, SET/20 RED RET...

18

19

20

Out[16]: 340.0 In [17]: # Número de datos que contiene la segunda regla más usada: "ALARM CLOCK BAKELIKE RED" basket["ALARM CLOCK BAKELIKE RED"].sum() Out[17]: 316.0

In [19]:

basket_sets2 = basket2.applymap(encode_units) basket_sets2.drop('POSTAGE', inplace=True, axis=1) frequent_itemsets2 = apriori(basket_sets2, min_support=0.05, use_colnames=True) rules2 = association_rules(frequent_itemsets2, metric="lift", min_threshold=1)

> /home/isabelmaniega/FEI_projects/venv/lib/python3.8/site-packages/mlxtend/frequent_patterns/fpcommon.py:111: De precationWarning: DataFrames with non-bool types result in worse computationalperformance and their support mig ht be discontinued in the future. Please use a DataFrame with bool type warnings.warn(

(rules2['confidence'] >= 0.5)]

Realizaremos un análisis para la compra en Alemania

basket2 = (df[df['Country'] =="Germany"]

rules2[(rules2['lift'] >= 4) &

SPACEBOY)

(RED RETROSPOT

CHARLOTTE BAG)

10

Isabel Maniega

.set_index('InvoiceNo'))

antecedent Out[19]: antecedents consequents (PLASTERS IN TIN (PLASTERS IN TIN 0 0.115974 CIRCUS PARADE) WOODLAND ANIMALS) (PLASTERS IN TIN (PLASTERS IN TIN 0.107221

Out[20]: 774.0 Creado por:

In [20]: basket2["PLASTERS IN TIN CIRCUS PARADE"].sum()